

# Evidências de Execução do MVP

Pipeline Lakehouse para Análise de Acidentes de Trânsito no Município do Rio de Janeiro

**Autor:** Anderson Gonçalves Portella

**Disciplina:** Engenharia de Dados - PUC-Rio

Documento complementar ao repositório técnico. Seu objetivo é apresentar evidências visuais da execução do pipeline no Databricks, incluindo ingestão, persistência, catálogo, qualidade e respostas às perguntas analíticas.

**Escopo:** RENAEST/SENATRAN como fonte principal; IPP/PCRJ como fonte complementar territorial; arquitetura Landing → Bronze → Silver → Gold → Qualidade/Analytics.

## Organização das evidências

As evidências a seguir complementam o README e a documentação técnica do repositório. Os screenshots foram obtidos do ambiente Databricks utilizado no MVP e mostram células executadas, resultados persistidos e saídas analíticas. A documentação detalhada permanece no repositório, incluindo contexto de negócio, fontes, arquitetura, modelagem, catálogo, pipeline, qualidade, análises e autoavaliação.

**Observação sobre licenciamento:** a licença MIT do repositório aplica-se ao código-fonte e à documentação produzidos para o projeto. As fontes RENAEST/SENATRAN e IPP/PCRJ são tratadas no documento de fontes como dados públicos disponibilizados pelos respectivos órgãos, preservando-se identificação e proveniência.

**Limitações relevantes:** a informação de bairro está preenchida em 51,14% dos 55.046 acidentes; a associação segura às Regiões Administrativas cobre 49,19%; 2023 e 2024 possuem 10 meses no conjunto analisado. Essas limitações são explicitadas nas análises e não foram ocultadas por imputações automáticas.

# 1. Coleta e rastreabilidade

✓ Sep 19, 2026 (5s)

8: Validação dos metadados Bronze

```
# Validação do metadado de origem antes da gravação das tabelas
df_bronze_tipo_veiculo.select(
  "_arquivo_origem",
  "_sistema_origem",
  "_data_ingestao"
).limit(1).display()
```

> [See performance \(1\)](#)

✓ Checked for improvements

Table ▾ +

|   | _arquivo_origem                                                              | _sistema_origem  | _data_ingestao                 |
|---|------------------------------------------------------------------------------|------------------|--------------------------------|
| 1 | dbfs:/Volumes/workspace/bronze/landing/TipoVeiculo_DadosAbertos_20250512.csv | RENAEST/SENATRAN | 2026-09-19T13:31:05.341+00:... |

▾

1 row | 5.345s runtime

Refreshed 7d ago

**Evidência:** Metadados de origem antes da gravação Bronze: arquivo de origem, sistema RENAEST/SENATRAN e data de ingestão.

*Evidencia a procedência e a rastreabilidade da ingestão.*

## 2. Persistência na camada Bronze

```
▶ ✓ Sep 19, 2026 (19s) 11: Gravação Bronze - Acidentes

# Persistência da tabela Acidentes na camada Bronze
(
  df_bronze_acidentes.write
    .format("delta")
    .mode("overwrite")
    .saveAsTable("workspace.bronze.acidentes")
)

print("Tabela workspace.bronze.acidentes gravada com sucesso.")
> See performance \(1\) ✓ Checked for improvements

Tabela workspace.bronze.acidentes gravada com sucesso.
```

**Evidência:** Persistência da tabela workspace.bronze.acidentes em formato Delta, com confirmação de gravação bem-sucedida.

*Evidência representativa da persistência da camada Bronze.*

### 3. Persistência física da camada Gold

▶

✓ 16 hours ago (2s)

38: Validação final da camada Gold

Python



```
# Validação física das tabelas da camada Gold

tabelas_gold = [
    "workspace.gold.dim_tempo",
    "workspace.gold.dim_horario",
    "workspace.gold.dim_bairro",
    "workspace.gold.dim_regiao",
    "workspace.gold.fato_acidentes"
]

for tabela in tabelas_gold:
    quantidade = spark.table(tabela).count()
    print(f"{tabela}: {quantidade} registros")
```

> [See performance \(5\)](#)

✓ Checked for improvements

```
workspace.gold.dim_tempo: 2434 registros
workspace.gold.dim_horario: 1319 registros
workspace.gold.dim_bairro: 311 registros
workspace.gold.dim_regiao: 34 registros
workspace.gold.fato_acidentes: 55046 registros
```

**Evidência:** Validação final das cinco tabelas Gold: dim\_tempo (2.434), dim\_horario (1.319), dim\_bairro (311), dim\_regiao (34) e fato\_acidentes (55.046).

*Comprova a existência e a volumetria das tabelas persistidas.*

## 4. Modelagem e catálogo - Unity Catalog

Catalog

Serverless Starter Warehouse Serverless 2XS

Catalog

Type to search

My organization

workspace

bronze

default

gold

Tables (5)

dim\_bairro

dim\_horario

dim\_regiao

dim\_tempo

fato\_acidentes

information\_schema

silver

system

Shares received

samples

Filter columns...

AI generate

| Column                 | Type   | Popularity | Comment | Tags | Column masking |
|------------------------|--------|------------|---------|------|----------------|
| num_acidente           | string | ----       |         |      |                |
| id_tempo               | int    | ----       |         |      |                |
| id_horario             | int    | ----       |         |      |                |
| id_bairro              | bigint | ----       |         |      |                |
| id_regiao              | int    | ----       |         |      |                |
| qtde_acidente          | int    | ----       |         |      |                |
| qtde_acid_com_obitos   | string | ----       |         |      |                |
| qtde_envolvidos        | int    | ----       |         |      |                |
| qtde_feridosileosos    | int    | ----       |         |      |                |
| qtde_obitos            | int    | ----       |         |      |                |
| tipo_acidente          | string | ----       |         |      |                |
| condicao_meteorologica | string | ----       |         |      |                |
| condicao_pista         | string | ----       |         |      |                |
| fase_dia               | string | ----       |         |      |                |
| tipo_pista             | string | ----       |         |      |                |
| tipo_pavimento         | string | ----       |         |      |                |
| tipo_rodovia           | string | ----       |         |      |                |

**Evidência:** Unity Catalog exibindo as cinco tabelas do schema workspace.gold e o esquema físico da fato\_acidentes.

*Evidencia o modelo persistido e os campos/tipos físicos da tabela fato.*

MVP - Engenharia de Dados - PUC-Rio

Página 6

## 5. Qualidade - implementação do resumo

```

# Resumo consolidado dos principais resultados de qualidade

resumo_qualidade = [
  (
    "Completo",
    "bairro_acidente",
    "51,14% preenchido",
    "ATENCAO",
    "Ausência concentrada principalmente entre 2018 e 2020."
  ),
  (
    "Completo",
    "Dados atributos críticos avaliados",
    "100% preenchidos",
    "OK",
    "Sem valores nulos após tratamento Silver."
  ),
  (
    "Unicidade",
    "num_acidente",
    "0 duplicados",
    "OK",
    "55.046 identificadores distintos para 55.046 registros."
  ),
  (
    "Validade temporal",
    "data_acidente / hora_acidente",
    "0 inconsistências",
    "OK",
    "Datas entre 2018-01-01 e 2024-11-30; horas entre 0 e 23."
  ),
  (
    "Validade quantitativa",
    "Medidas do acidente",
    "0 violações",
    "OK",
    "Sem negativos e sem violações das relações quantitativas testadas."
  ),
  (
    "Integridade referencial",
    "Gold",
    "0 chaves defeituosas",
    "OK",
    "As quatro FEs de fato possuem correspondência nas dimensões."
  ),
  (
    "Consistência territorial",
    "Bairro x IPP",
    "40,19% associados",
    "ATENCAO",
    "48,86% sem bairro e 1,96% com bairro não associado à referência oficial."
  ),
  (
    "Reconciliação",
    "Bronze -> Silver -> Gold",
    "55.046 -> 55.046 -> 55.046",
    "OK",
    "Nenhuma perda ou multiplicação de acidentes entre as camadas."
  )
]

df_resumo_qualidade = spark.createDataFrame(
  resumo_qualidade,
  [
    "dimensao_qualidade",
    "objeto_avaliado",
    "resultado",
    "status",
    "observacao"
  ]
)

display(df_resumo_qualidade)
```

**Evidência:** Célula de consolidação dos principais controles de qualidade.

*Inclui completude, unicidade, validade, integridade referencial, consistência territorial e reconciliação.*

## 6. Qualidade - resultados

> [See performance \(1\)](#)

✓ Checked for improvements

> `df_resumo_qualidade: pyspark.sql.connect.dataframe.DataFrame = [dimensao_qualidade: string, objeto_avaliado: string ... 3 more fields]`

Table +

🔍 ⚙️ 📄

|   | <sup>B</sup> <sub>C</sub> dimensao_qualidade | <sup>B</sup> <sub>C</sub> objeto_avaliado | <sup>B</sup> <sub>C</sub> resultado | <sup>B</sup> <sub>C</sub> status | <sup>B</sup> <sub>C</sub> observacao                                     |
|---|----------------------------------------------|-------------------------------------------|-------------------------------------|----------------------------------|--------------------------------------------------------------------------|
| 1 | Compleitude                                  | bairro_acidente                           | 51,14% preenchido                   | ATENCAO                          | Ausência concentrada principalmente entre 2018 e 2020.                   |
| 2 | Compleitude                                  | Demais atributos críticos avaliados       | 100% preenchidos                    | OK                               | Sem valores nulos após tratamento Silver.                                |
| 3 | Unicidade                                    | num_acidente                              | 0 duplicados                        | OK                               | 55.046 identificadores distintos para 55.046 registros.                  |
| 4 | Validade temporal                            | data_acidente / hora_acidente             | 0 inconsistências                   | OK                               | Datas entre 2018-01-01 e 2024-11-30; horas entre 0 e 23.                 |
| 5 | Validade quantitativa                        | Medidas do acidente                       | 0 violações                         | OK                               | Sem negativos e sem violações das relações quantitativas testadas.       |
| 6 | Integridade referencial                      | Gold                                      | 0 chaves órfãs                      | OK                               | As quatro FKs da fato possuem correspondência nas dimensões.             |
| 7 | Consistência territorial                     | Bairro x IPP                              | 49,19% associados                   | ATENCAO                          | 48,86% sem bairro e 1,96% com bairro não associado à referência oficial. |
| 8 | Reconciliação                                | Bronze -> Silver -> Gold                  | 55.046 -> 55.046 -> 55.046          | OK                               | Nenhuma perda ou multiplicação de acidentes entre as camadas.            |

📄

8 rows | 0.697s runtime

Refreshed 7d ago

**Evidência:** Resumo executado dos controles de qualidade.

*Destaques: 0 duplicidades, 0 chaves órfãs e reconciliação de 55.046 registros entre Bronze, Silver e Gold; limitações territoriais explicitadas.*

MVP - Engenharia de Dados - PUC-Rio

Página 8

## 7. Pergunta 1 - Acidentes por bairro

Table +

Q F I □

|    | <sup>A</sup> <sub>C</sub> bairro | <sup>1</sup> <sub>2</sub> <sup>2</sup> <sub>3</sub> total_acidentes |
|----|----------------------------------|---------------------------------------------------------------------|
| 1  | CAMPO GRANDE                     | 1618                                                                |
| 2  | BARRA DA TIJUCA                  | 1360                                                                |
| 3  | BANGU                            | 1011                                                                |
| 4  | SANTA CRUZ                       | 809                                                                 |
| 5  | CENTRO                           | 797                                                                 |
| 6  | BONSUCESSO                       | 776                                                                 |
| 7  | RECREIO DOS BANDEIRANT...        | 772                                                                 |
| 8  | GUARATIBA                        | 750                                                                 |
| 9  | REALENGO                         | 725                                                                 |
| 10 | TAQUARA                          | 549                                                                 |
| 11 | JACAREPAGUA                      | 547                                                                 |
| 12 | BOTAFOGO                         | 521                                                                 |
| 13 | TIJUCA                           | 510                                                                 |
| 14 | COPACABANA                       | 504                                                                 |
| 15 | MADUREIRA                        | 436                                                                 |

↓ ▾

20 rows4.453s runtime

Refreshed 7d ago

**Evidência:** Ranking de acidentes por bairro.  
*Campo Grande apresenta a maior frequência entre os acidentes com bairro identificado.*

## 8. Pergunta 2 - Sazonalidade mensal

Table +

Q F I

|    | 1 <sup>2</sup> <sub>3</sub> mes | 1.2 media_mensal | 1 <sup>2</sup> <sub>3</sub> total_perodo | 1 <sup>2</sup> <sub>3</sub> minimo | 1 <sup>2</sup> <sub>3</sub> maximo |
|----|---------------------------------|------------------|------------------------------------------|------------------------------------|------------------------------------|
| 1  | 1                               | 649.4            | 3247                                     | 554                                | 740                                |
| 2  | 2                               | 615.8            | 3079                                     | 514                                | 701                                |
| 3  | 3                               | 695.2            | 3476                                     | 448                                | 900                                |
| 4  | 4                               | 604.2            | 3021                                     | 259                                | 870                                |
| 5  | 5                               | 610              | 3050                                     | 272                                | 805                                |
| 6  | 6                               | 654.2            | 3271                                     | 360                                | 827                                |
| 7  | 7                               | 644.6            | 3223                                     | 492                                | 797                                |
| 8  | 8                               | 734.6            | 3673                                     | 565                                | 885                                |
| 9  | 9                               | 651.6            | 3258                                     | 426                                | 814                                |
| 10 | 10                              | 705.4            | 3527                                     | 577                                | 861                                |
| 11 | 11                              | 675              | 3375                                     | 532                                | 772                                |
| 12 | 12                              | 701              | 3505                                     | 517                                | 900                                |

↓

12 rows

2.630s runtime

Refreshed 7d ago

**Evidência:** Sazonalidade mensal calculada somente com anos completos (2018-2022).  
*Agosto apresenta a maior média mensal: 734,6 acidentes.*

## 9. Pergunta 3 - Acidentes por dia da semana

Sep 19, 2026 (2s)

10: Acidentes por dia da semana

```
# Pergunta 3:
# Quais dias da semana apresentam maior frequência de acidentes?

acidentes_dia_semana = (
    fato.alias("f")
    .join(
        dim_tempo.alias("t"),
        F.col("f.id_tempo") == F.col("t.id_tempo"),
        "inner"
    )
    .groupBy(
        F.col("t.dia_semana_num"),
        F.col("t.dia_semana")
    )
    .agg(
        F.count("*").alias("total_acidentes")
    )
    .withColumn(
        "participacao_percentual",
        F.round(
            F.col("total_acidentes")
            / F.lit(fato.count()) * 100,
            2
        )
    )
    .orderBy(F.desc("total_acidentes"))
)

display(acidentes_dia_semana)
```

> See performance (2)

✓ Checked for improvements

acidentes\_dia\_semana: pyspark.sql.connect.dataframe.DataFrame = [dia\_semana\_num: integer, dia\_semana: string ... 2 more fields]

Table

+

🔍

🔼

🔽

📄

|   | 1.3 dia_semana_num | 1.0 dia_semana | 1.2 total_acidentes | 1.2 participacao_percentual |
|---|--------------------|----------------|---------------------|-----------------------------|
| 1 | 2                  | SEGUNDA-FEIRA  | 8248                | 14.98                       |
| 2 | 5                  | QUINTA-FEIRA   | 8211                | 14.92                       |
| 3 | 6                  | SEXTA-FEIRA    | 8181                | 14.86                       |
| 4 | 4                  | QUARTA-FEIRA   | 7795                | 14.16                       |
| 5 | 3                  | TERÇA-FEIRA    | 7591                | 13.79                       |
| 6 | 1                  | DOMINGO        | 7552                | 13.72                       |
| 7 | 7                  | SABADO         | 7468                | 13.57                       |

📄

7 rows

1.838s runtime

Refreshed 7d ago

**Evidência:** Distribuição dos acidentes por dia da semana.

Segunda-feira apresenta a maior frequência (8.248; 14,98%), com distribuição relativamente homogênea entre os dias.

## 10. Pergunta 4 - Horários das ocorrências

Table +

|    | 1.2 hora | 1.2 total_acidentes | 1.2 participacao_percentual |
|----|----------|---------------------|-----------------------------|
| 10 | 9        | 2660                | 4.83                        |
| 11 | 10       | 2776                | 5.04                        |
| 12 | 11       | 2752                | 5                           |
| 13 | 12       | 2798                | 5.08                        |
| 14 | 13       | 2703                | 4.91                        |
| 15 | 14       | 2749                | 4.99                        |
| 16 | 15       | 2952                | 5.36                        |
| 17 | 16       | 2866                | 5.21                        |
| 18 | 17       | 3145                | 5.71                        |
| 19 | 18       | 3348                | 6.08                        |
| 20 | 19       | 3349                | 6.08                        |
| 21 | 20       | 2769                | 5.03                        |
| 22 | 21       | 2471                | 4.49                        |
| 23 | 22       | 2164                | 3.93                        |
| 24 | 23       | 1809                | 3.29                        |

Download

24 rows | 1.563s runtime

Refreshed 7d ago

**Evidência:** Distribuição das ocorrências nas horas finais do dia.  
19h (3.349) e 18h (3.348) apresentam as maiores frequências por hora.

## 11. Pergunta 5 - Regiões Administrativas

> `acidentes_por_regiao:` pyspark.sql.connect.dataframe.DataFrame = [id\_regiao: integer, regiao\_administrativa: string ... 3 more fields]

Acidentes com RA determinada: 27075  
Cobertura da análise regional: 49.19%

Table +

|    | i <sub>3</sub> id_regiao | A <sub>0</sub> regiao_administrativa | i <sub>3</sub> area_planejamento | i <sub>3</sub> total_acidentes | 1.2 participacao_percentual |
|----|--------------------------|--------------------------------------|----------------------------------|--------------------------------|-----------------------------|
| 1  | 24                       | BARRA DA TIJUCA                      | 4                                | 2397                           | 8.85                        |
| 2  | 18                       | CAMPO GRANDE                         | 5                                | 2259                           | 8.34                        |
| 3  | 16                       | JACAREPAGUA                          | 4                                | 2055                           | 7.59                        |
| 4  | 13                       | MEIER                                | 3                                | 1798                           | 6.64                        |
| 5  | 15                       | MADUREIRA                            | 3                                | 1560                           | 5.76                        |
| 6  | 10                       | RAMOS                                | 3                                | 1356                           | 5.01                        |
| 7  | 33                       | REALENGO                             | 5                                | 1316                           | 4.86                        |
| 8  | 17                       | BANGU                                | 5                                | 1314                           | 4.85                        |
| 9  | 4                        | BOTAFOGO                             | 2                                | 1165                           | 4.3                         |
| 10 | 19                       | SANTA CRUZ                           | 5                                | 1149                           | 4.24                        |
| 11 | 11                       | PENHA                                | 3                                | 891                            | 3.29                        |
| 12 | 26                       | GUARATIBA                            | 5                                | 863                            | 3.19                        |
| 13 | 2                        | CENTRO                               | 1                                | 801                            | 2.96                        |
| 14 | 12                       | INHAUMA                              | 3                                | 793                            | 2.93                        |
| 15 | 20                       | ILHA DO GOVERNADOR                   | 3                                | 724                            | 2.67                        |

Download 20 rows | 2.521s runtime Refreshed 7d ago

**Evidência:** Distribuição dos acidentes com Região Administrativa determinada.

*Cobertura regional de 49,19%; Barra da Tijuca apresenta a maior frequência entre os registros associados.*

## 12. Pergunta 6 - Evolução anual

✓ Sep 19, 2026 (2s)

17: Análise — Evolução anual do total de acidentes

# Pergunta 6:  
# Como evoluiu o número de acidentes ao longo dos anos?

evolucao\_anual = (  
 fato.alias("f")  
 .join(  
 dim\_tempo.alias("t"),  
 F.col("f.id\_tempo") == F.col("t.id\_tempo"),  
 "inner"  
 )  
 .groupBy(  
 F.col("t.ano")  
 )  
 .agg(  
 F.count("\*").alias("total\_acidentes"),  
 F.countDistinct("t.mes").alias("meses\_disponiveis")  
 )  
 .orderBy("ano")  
)  
  
display(evolucao\_anual)

> [See performance \(1\)](#)

✓ Checked for improvements

> evolucao\_anual: pyspark.sql.connect.dataframe.DataFrame = [ano: integer, total\_acidentes: long ... 1 more field]

Table +

🔍 🔍 📄 📄

|   | <sup>1</sup> ano | <sup>1</sup> total_acidentes | <sup>1</sup> meses_disponiveis |
|---|------------------|------------------------------|--------------------------------|
| 1 | 2018             | 9683                         | 12                             |
| 2 | 2019             | 9449                         | 12                             |
| 3 | 2020             | 6036                         | 12                             |
| 4 | 2021             | 6918                         | 12                             |
| 5 | 2022             | 7619                         | 12                             |
| 6 | 2023             | 7799                         | 10                             |
| 7 | 2024             | 7542                         | 10                             |

📄

7 rows | 1.828s runtime

Refreshed 7d ago

**Evidência:** Evolução anual do total de acidentes e quantidade de meses disponíveis.  
2018-2022 possuem 12 meses; 2023 e 2024 possuem 10 meses, portanto seus totais não são diretamente comparáveis aos anos completos.

### 13. Pergunta 7 - Impactos dos problemas de qualidade

> df\_impacto\_qualidade: pyspark.sql.connect.dataframe.DataFrame = [problema: string, evidencia: string ... 1 more field]

Table +

Q F I

|   | A <sup>B</sup> <sub>C</sub> problema          | A <sup>B</sup> <sub>C</sub> evidencia                 | A <sup>B</sup> <sub>C</sub> impacto_analitico                                                 |
|---|-----------------------------------------------|-------------------------------------------------------|-----------------------------------------------------------------------------------------------|
| 1 | Ausência de bairro                            | 26.894 acidentes (48,86%)                             | Reduz a cobertura das análises por bairro e Região Administrativa.                            |
| 2 | Baixa completude territorial em 2018-2020     | 0,00% em 2018; 0,01% em 2019; 0,25% em 2020           | Impede comparação territorial representativa desses anos com 2021-2024.                       |
| 3 | Bairro não associado ao cadastro oficial      | 1.077 acidentes (1,96%)                               | Pode produzir classificação incorreta de Região Administrativa se houver correção automáti... |
| 4 | Grafias e valores não padronizados de bair... | Ex.: OSWALDO CRUZ, 00000000 e BAIRRO NAO CADASTRAD... | Pode fragmentar bairros, criar categorias inválidas e distorcer rankings.                     |
| 5 | Cobertura mensal incompleta                   | 2023 e 2024 possuem 10 meses registrados              | Totais anuais desses anos não são diretamente comparáveis aos anos completos.                 |

Download

5 rows | 1.157s runtime

Refreshed 7d ago

**Evidência:** Síntese dos problemas de qualidade e seus impactos analíticos.

A ausência de bairro, a baixa completude territorial, grafias não padronizadas e a cobertura mensal incompleta são explicitamente consideradas na interpretação.